

Análisis y Procesamiento OLAP

Objetivo

Esta etapa se enfoca en la implementación de capacidades de análisis de datos mediante soluciones OLAP, procesamiento de datos con Spark, rutas de entrega optimizadas, uso de grafos con Neo4J y visualización con herramientas libres. Además, se integrará un pipeline de orquestación de datos con Apache Airflow.

Componentes y Requerimientos

1. Arquitectura OLAP y Almacén de Datos

- Crear un esquema estrella o copo de nieve que consolide datos históricos de reservas, productos, pedidos y usuarios.
- Implementar un Data Warehouse utilizando herramientas open-source como Apache Hive.
- Crear al menos 5 cubos o vistas OLAP que permitan análisis agregados por tiempo, ubicación, tipo de producto y frecuencia de uso.

2. Procesamiento con Apache Spark

- Procesar grandes volúmenes de datos de órdenes, productos y reservas.
- Implementar transformaciones con Spark DataFrames y SparkSQL.
- Realizar al menos tres tipos de análisis: tendencias de consumo, horarios pico, crecimiento mensual.

3. Visualización de Datos

- Utilizar una herramienta libre como Apache Superset, Metabase o Redash.
- Construir al menos tres dashboards:
 - Ingresos por mes y categoría de producto.
 - Actividad de clientes por zona geográfica.
 - Estadísticas de pedidos completados vs cancelados.

4. Orquestación con Apache Airflow

- Diseñar un DAG en Airflow que integre:
 - Extracción de datos de MongoDB o PostgreSQL.
 - Transformación con Spark.
 - Carga en el Data Warehouse.
 - Reindexado de ElasticSearch si cambia el catálogo de productos.

5. Uso de Neo4J para Análisis de Grafos y Rutas

- Modelar la relación entre usuarios, productos y pedidos en un grafo.
- Identificar patrones de co-compra y usuarios influyentes en recomendaciones.
- Simular y optimizar rutas de entrega usando geonodos y relaciones de distancia o tiempo estimado.
- Crear consultas en Cypher para obtener:
 - Los 5 productos más comprados juntos.
 - Usuarios que recomiendan a otros.
 - Caminos mínimos entre ubicaciones para reparto eficiente.

6. Asignación de Rutas de Entrega

- Diseñar un módulo para simular rutas de entrega para pedidos con geolocalización de clientes.
- Utilizar heurísticas simples como algoritmo de vecino más cercano o consultas en Neo4J para encontrar caminos óptimos.
- Mostrar rutas optimizadas y asignaciones por repartidor.

Pruebas y Validaciones

- Verificar integridad de los datos en el warehouse.
- Validar la ejecución periódica del pipeline con Airflow.
- Validar resultados de Spark y Neo4J con consultas y reportes exportables.

Entregables

- Código fuente y DAG de Airflow.
- Script o notebooks de Spark.
- Dashboards configurados exportables.
- Consultas Cypher y estructura del grafo.
- Capturas de pantalla o video demostrativo.
- Documentación técnica en PDF explicando el flujo de datos, decisiones de diseño y ejemplos de uso.

Evaluación

- **Data Warehouse y OLAP (20%):** Correcta modelación y funcionalidad.
- **Procesamiento con Spark (20%):** Transformaciones y análisis realizados.
- **Visualización (15%):** Dashboards informativos y bien presentados.
- **Airflow (15%):** DAG funcional, modular y programado.
- **Neo4J (15%):** Consultas útiles, grafo representativo, análisis y rutas.
- **Enrutamiento (10%):** Lógica coherente y rutas óptimas simuladas.
- **Documentación (5%):** Claridad, diagramas y explicación completa.

Fecha de Entrega

Entrega en formato comprimido antes de las 10:00 p.m. del día acordado. Penalización de 5% por cada 24 horas de retraso.